

Detección de tráfico DDoS mediante comportamiento de flujo de red usando CICIDS2017

Diego Perdomo
Universidad del Valle de Guatemala
Security Data Science

Resumen

Este trabajo evalúa si el comportamiento de red a nivel de flujo permite distinguir tráfico benigno de tráfico DDoS. El proyecto fue reformulado después de identificar que el dataset inicialmente considerado no contenía una clase benigna explícita, lo cual impedía entrenar un clasificador supervisado binario válido. Para corregir esa debilidad metodológica se utilizó CICIDS2017, específicamente el archivo Friday-WorkingHours-Afternoon-DDoS.pcap_ISCX.csv, que contiene tráfico BENIGN y DDoS etiquetado. Se implementaron Logistic Regression como línea base, Random Forest como modelo principal y una versión refinada de Random Forest usando las 20 características más importantes. Los resultados reportados muestran alta separabilidad interna entre ambas clases: Random Forest obtuvo accuracy de 0.999933, precision de 0.999961, recall de 0.999922, F1-score de 0.999941 y ROC-AUC de 1.000000. No obstante, la interpretación se limita al escenario experimental evaluado: un único archivo de un benchmark histórico, con partición aleatoria estratificada. Por ello, el trabajo sostiene una conclusión fuerte de validez interna, pero no una garantía de generalización en producción.

Palabras clave

DDoS; CICIDS2017; clasificación supervisada; Random Forest; Logistic Regression; tráfico de red; detección de intrusiones; flow-level features.

1. Introducción

Los ataques de denegación de servicio distribuida (DDoS) siguen siendo una amenaza relevante para servicios expuestos a internet, infraestructuras empresariales, plataformas financieras, telecomunicaciones, videojuegos y servicios públicos. Un ataque DDoS busca degradar o interrumpir la disponibilidad de un servicio mediante tráfico originado desde múltiples fuentes, normalmente coordinadas o comprometidas. La persistencia de esta amenaza justifica estudiar métodos automáticos que permitan distinguir tráfico normal de patrones de ataque.

La inspección manual de grandes volúmenes de tráfico no escala operativamente. Por ello, los sistemas de detección de intrusiones y los modelos de aprendizaje automático se han explorado como mecanismos de apoyo para identificar patrones anómalos o maliciosos. Sin embargo, la literatura advierte que el éxito en datasets controlados no equivale automáticamente a efectividad en producción, debido al

cambio de distribución, a la adaptación de atacantes y a la dependencia del contexto de captura.

La pregunta de investigación corregida es: ¿Puede el comportamiento de red a nivel de flujo distinguir el tráfico benigno del tráfico de DDoS? Esta formulación acota el proyecto a un problema binario y medible: clasificar flujos de red como BENIGN o DDoS utilizando características estadísticas de flujo.

2. Reformulación metodológica del proyecto

La versión inicial del proyecto proponía detectar interacciones web sospechosas usando un dataset de Kaggle. Durante la revisión se identificó una debilidad crítica: el dataset inicial contenía únicamente registros sospechosos o maliciosos, sin una clase benigna explícita. Bajo esas condiciones, un modelo supervisado no puede aprender una frontera válida entre tráfico normal y tráfico malicioso.

Para corregir esta limitación, se sustituyó el dataset de modelado por CICIDS2017. El cambio no abandona el objetivo de ciberseguridad; lo vuelve metodológicamente defendible. CICIDS2017 incluye tráfico benigno y distintos ataques etiquetados, y el archivo del viernes por la tarde permite concentrarse en BENIGN vs DDoS. La conclusión del trabajo, por tanto, se restringe al escenario evaluado y no pretende demostrar detección general de intrusiones.

3. Estado del arte sintetizado

La literatura sobre aprendizaje automático aplicado a detección de intrusiones coincide en tres puntos. Primero, los modelos supervisados pueden alcanzar alto rendimiento cuando existen datos etiquetados y características informativas. Segundo, la calidad del dataset, el proceso de etiquetado y la representatividad del tráfico son determinantes para interpretar los resultados. Tercero, métricas como precision, recall, F1-score y ROC-AUC ofrecen una lectura más útil que accuracy aislada, especialmente cuando las clases están desbalanceadas o cuando los falsos negativos tienen alto costo operativo.

Sommer y Paxson advierten que la detección de intrusiones no opera en un mundo cerrado: el tráfico cambia, los atacantes se adaptan y los modelos pueden sobreajustarse a artefactos del dataset. Buczak y Guven ofrecen una revisión amplia de minería de datos y machine learning para ciberseguridad, destacando la importancia del preprocesamiento, selección de atributos y evaluación. Sharafaldin, Habibi Lashkari y Ghorbani son la referencia primaria para CICIDS2017.

Además, trabajos posteriores han identificado problemas en CICIDS2017 y otros benchmarks NIDS, incluyendo errores de etiquetado, dependencia temporal, construcción de flujos y sesgos de diseño. Por ello, CICIDS2017 debe tratarse como un benchmark histórico útil para experimentación académica, no como una representación plena del tráfico actual de producción.

4. Dataset y preparación de datos

El experimento utiliza el archivo Friday-WorkingHours-Afternoon-DDos.pcap_ISCX.csv de CICIDS2017. La copia local cargada en el notebook contiene 225,745 filas y 79 columnas iniciales. Después de limpiar nombres de columnas, reemplazar valores infinitos, eliminar filas con NaN/inf y remover duplicados, el dataset final queda con 223,082 registros.

La variable objetivo se construyó de forma binaria: BENIGN = 0 y DDoS = 1. La distribución final fue de 95,068 registros BENIGN y 128,014 registros DDoS. La partición se realizó con 80% para entrenamiento y 20% para prueba, usando estratificación y random_state=42. El conjunto de prueba contiene 44,617 registros: 19,014 BENIGN y 25,603 DDoS.

Estos conteos deben interpretarse como resultados del pipeline local del autor, no como propiedades universales del dataset oficial. Para reproducibilidad estricta sería necesario documentar fecha de descarga, fuente exacta del CSV, hash del archivo y versiones completas de bibliotecas. El notebook identifica Python 3.12.10 y usa random_state=42 en la partición y modelos.

5. Diseño experimental

Se implementaron tres variantes de modelo. Logistic Regression se usó como línea base por su simplicidad e interpretabilidad. Random Forest se usó como modelo principal por su capacidad para capturar relaciones no lineales y ofrecer una estimación exploratoria de importancia de variables. Finalmente, se entrenó un Random Forest refinado usando las 20 variables con mayor importancia reportada por el modelo principal.

La evaluación incluyó accuracy, precision, recall, F1-score, matriz de confusión y ROC-AUC. En el contexto DDoS, recall es especialmente importante porque un falso negativo representa tráfico de ataque no detectado. Precision también importa porque una baja precision produce falsos positivos y fatiga operativa. F1-score permite balancear ambas dimensiones.

La partición aleatoria estratificada es aceptable como primera aproximación académica, pero no descarta por completo fuga de información, dependencia temporal o artefactos del escenario. Una evaluación más robusta requeriría separación temporal por bloques, validación entre días, comparación con otros ataques DoS/DDoS y prueba sobre capturas externas.

6. Resultados

La Tabla 1 resume los datos principales de carga, limpieza y partición del dataset local utilizado en el notebook.

Elemento	Valor
Archivo	Friday-WorkingHours-Afternoon-DDos.pcap_ISCX.csv
Filas iniciales	225,745
Columnas iniciales	79
Filas removidas por	34

NaN/inf	
Duplicados removidos	2,629
Filas finales	223,082
Variables predictoras finales	78
Clase BENIGN final	95,068
Clase DDoS final	128,014
Train/test split	80/20 estratificado, random_state=42
Filas de entrenamiento	178,465
Filas de prueba	44,617

La Tabla 2 muestra las métricas principales obtenidas por cada modelo. Los resultados son internamente consistentes con las matrices de confusión reportadas en el notebook.

Modelo	Accuracy	Precision	Recall	F1-score	ROC-AUC
Logistic Regression	0.998588	0.998517	0.999024	0.998770	0.999808
Random Forest	0.999933	0.999961	0.999922	0.999941	1.000000
Random Forest - Top 20	0.999888	0.999844	0.999961	0.999902	1.000000

La Tabla 3 presenta las matrices de confusión en forma resumida. Para todos los modelos se usa la clase positiva DDoS.

Modelo	TN BENIGN	FP	FN	TP DDoS	Errores totales
Logistic Regression	18,976	38	25	25,578	63
Random Forest	19,013	1	2	25,601	3
Random Forest - Top 20	19,010	4	1	25,602	5

La Tabla 4 agrega métricas derivadas a partir de las matrices: specificity y balanced accuracy. Estas métricas ayudan a evitar una lectura excesivamente dependiente de accuracy.

Modelo	Specificity	Balanced accuracy
Logistic Regression	0.998001	0.998513
Random Forest	0.999947	0.999935
Random Forest - Top 20	0.999790	0.999875

Las diez características más importantes reportadas por Random Forest se muestran en la Tabla 5. Se corrige aquí una inconsistencia de presentación de la versión anterior: la tabla visible contiene Top 10, mientras que el modelo refinado usa Top 20 en el notebook.

Posición	Característica	Importancia
1	Init_Win_bytes_forward	0.082848
2	Bwd Packet Length Max	0.057863
3	Fwd Packet Length Mean	0.056224
4	Avg Fwd Segment Size	0.054591
5	Fwd Packet Length Max	0.053549
6	Subflow Fwd Bytes	0.050942
7	Avg Bwd Segment Size	0.043706
8	Total Length of Fwd Packets	0.040863
9	act_data_pkt_fwd	0.039932
10	Destination Port	0.033913

7. Interpretación de métricas

Los resultados muestran que, dentro de esta partición concreta, las características de flujo separan de forma extraordinariamente clara el tráfico BENIGN del tráfico DDoS. Random Forest fue el mejor modelo por margen pequeño: sólo cometió 3 errores sobre 44,617 registros de prueba. La versión con Top 20 características cometió 5 errores, por lo que mantiene casi toda la señal predictiva reduciendo dimensionalidad.

Un ROC-AUC de 1.000000 no contradice la existencia de algunos errores con un umbral fijo. ROC-AUC mide la capacidad de ranking del modelo a través de distintos umbrales, mientras que la matriz de confusión refleja decisiones binarias en un punto de corte específico. Por ello, ambos resultados pueden coexistir.

En ciberseguridad, recall y F1-score son más informativos que accuracy aislada. Un alto recall reduce el riesgo de dejar pasar tráfico DDoS; una alta precision reduce falsos positivos y fatiga operativa. Dado que en producción la prevalencia real de DDoS puede ser muy distinta a la del benchmark, una mejora futura recomendable es reportar PR-AUC y analizar cambios de umbral.

8. Interpretación de características

Las variables más relevantes se relacionan con tamaño de paquetes, bytes transferidos, segmentos, paquetes activos y parámetros de ventana. Esto es coherente con el comportamiento esperado de un ataque DDoS volumétrico o de alta repetición, donde los flujos tienden a exhibir patrones estadísticos diferentes al tráfico benigno.

Sin embargo, esta interpretación debe tratarse como exploratoria. La importancia por impureza de Random Forest puede sesgarse hacia variables de alta cardinalidad o variables que capturan artefactos del escenario de laboratorio. Destination Port, por ejemplo, puede reflejar configuración específica del experimento más que una señal general de DDoS. Por ello, una validación más robusta debería usar permutation importance sobre el conjunto de prueba y análisis de correlación entre variables.

9. Limitaciones

La principal limitación es que el estudio usa un único archivo de CICIDS2017, correspondiente al escenario del viernes por la tarde con DDoS. Esto permite una evaluación clara y acotada, pero no demuestra capacidad general de detección de intrusiones ni generalización a otros días, ataques o entornos productivos.

La segunda limitación es la partición aleatoria estratificada. En datasets de red, los flujos pueden estar temporalmente relacionados o compartir artefactos de captura. Si flujos muy similares aparecen en entrenamiento y prueba, el rendimiento puede ser optimista. Una validación temporal o por grupos sería más rigurosa.

La tercera limitación es la reproducibilidad incompleta de la fuente exacta del CSV. El notebook documenta el archivo local, los conteos, random_state=42 y Python 3.12.10, pero no incluye hash del dataset, versión exacta de scikit-learn ni fecha de descarga. Para una entrega académica esto es aceptable si se reconoce explícitamente, pero para investigación reproducible debe corregirse.

CICIDS2017 debe describirse como benchmark histórico. Fue moderno en su momento y sigue siendo útil para aprendizaje y comparación, pero no debe presentarse como equivalente directo al tráfico DDoS contemporáneo. La amenaza DDoS sigue vigente; el benchmark utilizado pertenece a una generación anterior de datos.

10. Conclusión

La respuesta a la pregunta de investigación es afirmativa dentro del escenario evaluado: el comportamiento de red a nivel de flujo sí permite distinguir tráfico benigno de tráfico DDoS en el archivo Friday-WorkingHours-Afternoon-DDos.pcap_ISCX.csv de CICIDS2017. Los modelos supervisados alcanzaron métricas casi perfectas y Random Forest presentó el mejor rendimiento general.

La conclusión fuerte del trabajo es de validez interna: en esta copia del dataset, con este pipeline y esta partición, las clases BENIGN y DDoS son altamente separables. La conclusión no debe extenderse automáticamente a producción ni a tráfico moderno sin validaciones adicionales. Para fortalecer el proyecto, se recomienda ejecutar validación temporal, incorporar PR-AUC, calcular permutation importance y probar el modelo contra otros archivos o datasets.

Referencias

- Buczak, A. L., & Guven, E. (2016). A survey of data mining and machine learning methods for cyber security intrusion detection. *IEEE Communications Surveys & Tutorials*, 18(2), 1153-1176. <https://doi.org/10.1109/COMST.2015.2494502>
- Canadian Institute for Cybersecurity. (s. f.). Intrusion detection evaluation dataset (CIC-IDS2017). University of New Brunswick. <https://www.unb.ca/cic/datasets/ids-2017.html>
- Cloudflare. (2025). DDoS threat report for 2025 Q1. <https://blog.cloudflare.com/ddos-threat-report-for-2025-q1/>
- Engelen, G., Rimmer, V., & Joosen, W. (2021). Troubleshooting an intrusion detection dataset: The CICIDS2017 case study. 2021 IEEE Security and Privacy Workshops (SPW), 7-12. <https://doi.org/10.1109/SPW53761.2021.00009>
- European Union Agency for Cybersecurity. (2025). Threat landscape. <https://www.enisa.europa.eu/topics/cyber-threats/threat-landscape>
- Flood, R., Engelen, G., Aspinall, D., & Desmet, L. (2024). Bad design smells in benchmark NIDS datasets. 2024 IEEE 9th European Symposium on Security and Privacy (EuroS&P), 658-675. <https://doi.org/10.1109/EUROSP60621.2024.00042>
- Instituto Nacional de Ciberseguridad. (2023). Ataques DDoS: qué son y qué puedo hacer para proteger mi empresa. <https://www.incibe.es/empresas/blog/ataques-ddos-que-son-y-que-puedo-hacer-para-proteger-mi-empresa>
- Liu, L., Engelen, G., Lynar, T. M., Essam, D., & Joosen, W. (2022). Error prevalence in NIDS datasets: A case study on CIC-IDS-2017 and CSE-CIC-IDS-2018. 2022 IEEE Conference on Communications and Network Security (CNS), 254-263. <https://doi.org/10.1109/CNS56114.2022.9947235>
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, E. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12(85), 2825-2830.
- Saito, T., & Rehmsmeier, M. (2015). The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. *PLOS ONE*, 10(3), e0118432. <https://doi.org/10.1371/journal.pone.0118432>
- scikit-learn developers. (s. f.). Permutation feature importance. scikit-learn documentation. https://scikit-learn.org/stable/modules/permutation_importance.html
- Sharafaldin, I., Habibi Lashkari, A., & Ghorbani, A. A. (2018). Toward generating a new intrusion detection dataset and intrusion traffic characterization. *Proceedings of the 4th International Conference on Information Systems Security and Privacy*, 108-116. <https://doi.org/10.5220/0006639801080116>
- Sommer, R., & Paxson, V. (2010). Outside the closed world: On using machine learning for network intrusion detection. 2010 IEEE Symposium on Security and Privacy, 305-316. <https://doi.org/10.1109/SP.2010.25>